

Grupo: databois

Caso de Estudio 5:

Sector de la Salud y Farmacéutico

- Caso de Uso: Investigación médica y desarrollo de nuevos medicamentos.
- Descripción Ampliada: El Big Data está revolucionando la medicina, acelerando la investigación y mejorando los tratamientos.
 - Genómica y Datos Clínicos: Se analizan grandes volúmenes de datos genómicos (la secuencia completa del ADN de miles de personas) junto con sus historiales médicos, datos de dispositivos médicos y estilos de vida. Esto permite encontrar correlaciones entre genes y enfermedades, lo que antes era imposible de hacer a gran escala.
 - Fármacos Personalizados: Con estos análisis, se pueden desarrollar medicamentos que se adapten al perfil genético de un paciente, aumentando su efectividad y reduciendo los efectos secundarios.
 - Monitoreo de Pandemias: Durante la pandemia de COVID-19, se utilizaron datos masivos de movilidad, redes sociales, información de hospitales y pruebas de laboratorio para predecir la propagación del virus y tomar decisiones de salud Pública.

Investigación y Discusión:

- En tu grupo, analicen en profundidad el caso de estudio asignado.
- Utilicen los siguientes puntos como guía para su análisis y tomen notas de sus respuestas:
 - 1. Las 5 V's del Big Data:
 - Volumen: ¿Qué tipo de datos masivos se generan o manejan? ¿De qué escala hablamos (terabytes, petabytes)?
 - Velocidad: ¿Los datos se procesan en tiempo real o por lotes? ¿Por qué ¿Esa velocidad es crucial para el éxito de la empresa?
 - Variedad: ¿Qué tipos de datos se utilizan (estructurados, no estructurados, semi-estructurados)?
 - Veracidad: ¿Qué desafíos de calidad y confiabilidad de datos podrían enfrentar?
 - Valor: ¿Cuál es el beneficio de negocio (ganancias, eficiencia, satisfacción del cliente) que se obtiene del Big Data en este caso?
 - 2. Almacenamiento:
 - ¿Dónde se almacenarán estos datos? ¿Creen que sería un sistema de archivos distribuido como HDFS, un Data Lake o una base de datos más tradicional?
 - ¿Qué desafíos de escalabilidad y costo enfrentarían al almacenar estos datos?
 - 3. Procesamiento y Análisis:
 - ¿Qué tipo de procesamiento se necesita (por lotes o en streaming)?

- ¿Qué herramientas de análisis serían las más adecuadas (ej. SQL, Python, machine learning)?
- 4. Gobernanza y Seguridad:
 - ¿Qué datos sensibles o personales podrían estar manejando? (ej. datos personales de clientes, historial de navegación)?
 - ¿Qué desafíos de seguridad y privacidad tendrían que considerar para proteger la información?

1. Las 5 V del Big Data

Volumen

La investigación médica y farmacéutica trabaja con cantidades enormes de información y, además, de distintos tipos. Entre los principales flujos de datos aparecen las secuencias de ADN obtenidas mediante secuenciación de nueva generación (NGS), las imágenes diagnósticas de alta resolución, como tomografías y resonancias magnéticas en formato DICOM, las historias clínicas electrónicas y la telemetría generada de manera continua por dispositivos biométricos portátiles.

La escala de estos datos puede llegar a los Petabytes e incluso a los Exabytes. La secuencia completa del genoma de una persona, en formato bruto, suele requerir entre 100 y 200 GB de almacenamiento. Cuando esta información se recopila a nivel poblacional, el volumen crece rápidamente. Un ejemplo es el UK Biobank, que cuenta con datos genéticos y clínicos de más de 500.000 participantes y supera actualmente los 25 Petabytes de información almacenada.

Velocidad

El procesamiento de los datos necesita un modelo combinado, dependiendo del uso que se le quiera dar.

En tiempo real: Se utiliza principalmente para el monitoreo de pacientes en situaciones críticas, el seguimiento epidemiológico y el análisis de movilidad de la población durante brotes sanitarios. Un ejemplo concreto se encuentra en las salas de emergencias, donde la recepción constante de parámetros fisiológicos puede ayudar a detectar y anticipar eventos graves antes de que se manifiesten clínicamente.

Por lotes (Batch): Se aplica en tareas como el alineamiento de secuencias genómicas, el procesamiento de variantes y las simulaciones computacionales de interacciones moleculares.

utilizadas en el desarrollo de medicamentos. En estos casos, importa mas la capacidad de procesamiento que obtener una respuesta inmediata.

Esta capacidad para procesar informacion a distintas velocidades permite responder mas rapido ante situaciones de salud publica y, a su vez, disminuir los tiempos de las etapas preclínicas en la industria farmaceutica.

Variedad

Los datos biomédicos pueden dividirse en tres grandes categorías según su estructura:

Estructurados: Incluyen registros de parámetros fisiológicos, resultados de laboratorio y códigos estandarizados de diagnóstico, como ICD-10 o SNOMED-CT, que suelen organizarse en tablas relacionales.

Semi-estructurados: Comprenden archivos utilizados para el intercambio de información clínica, basados en estándares como HL7 o FHIR, generalmente en formatos JSON y XML. También pueden incluir archivos utilizados para el mapeo de variantes genéticas.

No estructurados: Abarcan informes médicos escritos en texto libre, imágenes diagnósticas, registros de señales eléctricas, como electrocardiogramas, y grandes cantidades de literatura científica.

Veracidad

La calidad y confiabilidad de los datos representan un desafio importante tanto desde el punto de vista etico como analítico. Las historias clinicas electronicas pueden presentar informacion incompleta, inconsistencias o errores derivados de la carga manual de datos.

Por otro lado, muchas bases de datos genomicas historicas tienen un marcado sesgo poblacional, ya que mas del 75% de las muestras corresponden a personas de ascendencia europea. Esto puede afectar la precision de los modelos cuando se utilizan en poblaciones diferentes.

Tambien existen problemas relacionados con los propios dispositivos de medicion. Por ejemplo, el movimiento involuntario de un paciente puede generar artefactos en imagenes o señales, mientras que la falta de calibracion de determinados sensores puede afectar la calidad de los datos obtenidos.

Valor

El principal aporte del Big Data en este sector esta relacionado con la mejora del desarrollo de tratamientos y con una mayor eficiencia en los procesos. Un caso muy conocido fue el

desarrollo de las vacunas de ARN mensajero contra el COVID-19, donde la disponibilidad del genoma del virus y las herramientas de analisis computacional permitieron avanzar con mucha rapidez en el diseño de las secuencias.

La integracion de grandes cantidades de datos tambien permite reducir costos de investigacion y desarrollo mediante simulaciones *in silico*, avanzar hacia una medicina mas personalizada y seleccionar tratamientos de acuerdo con el perfil genetico de cada paciente. Ademias, puede mejorar la planificacion y distribucion de recursos dentro de los sistemas de salud publica.

2. Almacenamiento

Arquitectura de almacenamiento

El manejo de archivos de gran tamaño y de formatos muy diferentes requiere una arquitectura capaz de escalar de acuerdo con el crecimiento de la informacion. Una alternativa habitual es utilizar un **Data Lake**, alojado sobre sistemas de archivos distribuidos como HDFS o servicios de almacenamiento en la nube, por ejemplo Amazon S3.

Esta estructura permite conservar archivos genomicos e imagenes biomedicas en su formato original, sin tener que definir un esquema rigido antes de incorporarlos al sistema.

Para facilitar su utilizacion, el Data Lake puede complementarse con bases de datos relacionales o NoSQL que funcionen como una capa de indexacion de los metadatos clinicos. De esta manera, es posible relacionar rapidamente la informacion de un paciente con los diferentes archivos almacenados.

Desafios de escalabilidad y costos

Las regulaciones del sector sanitario suelen exigir la conservacion de los historiales clinicos durante largos periodos. Esto genera un aumento considerable de los costos de almacenamiento e infraestructura.

Una estrategia para reducir estos gastos consiste en utilizar almacenamiento por capas o *tiering*:

- Los datos activos y consultados con frecuencia se mantienen en sistemas de alto rendimiento o **Hot Storage**.
- La informacion historica o correspondiente a estudios ya finalizados puede trasladarse a sistemas de menor costo o **Cold Storage**, como AWS Glacier. Esto reduce el gasto, aunque implica tiempos de recuperacion mas largos.

Ademas, el traslado de grandes cantidades de informacion genomica entre instituciones puede generar un consumo elevado de ancho de banda y costos adicionales asociados a la transferencia de datos.

3. Procesamiento y Analisis

Tipo de procesamiento

El analisis de grandes conjuntos de datos clinicos y genomicos requiere infraestructura de computo distribuido, capaz de dividir las tareas y ejecutarlas en paralelo.

Por lotes: Se utiliza para procesos pesados, como el procesamiento de secuencias de ADN, los estudios de asociacion del genoma completo (GWAS) y el entrenamiento de modelos analiticos.

En tiempo real: Se aplica principalmente al procesamiento continuo de informacion proveniente de sensores de telemedicina y sistemas de alerta temprana, donde es importante detectar cambios rapidamente.

Herramientas de analisis

Herramienta	Aplicacion en el sector
Apache Spark	Permite coordinar procesos de computo distribuido y trabajar en paralelo con grandes cantidades de datos.
Python y R	Se utilizan para analisis estadistico y bioinformatico, junto con librerias especializadas como Biopython y Bioconductor.
PyTorch y TensorFlow	Se emplean para entrenar modelos de aprendizaje profundo destinados, entre otras cosas, al analisis de imagenes medicas y al procesamiento de lenguaje natural de notas clinicas.
AlphaFold	Utiliza inteligencia artificial para predecir la estructura tridimensional de proteinas, lo que puede ser de utilidad en el diseño y desarrollo de farmacos.

SQL (Trino / Presto)

Permite realizar consultas sobre datos estructurados y semi-estructurados almacenados en el Data Lake.

4. Gobernanza y Seguridad

Datos sensibles manejados

La información administrada en este sector incluye **Información de Salud Protegida (PHI)** y datos genómicos. La información genética requiere especial cuidado porque funciona como un identificador biológico único y permanente. Además, puede revelar posibles predisposiciones a determinadas enfermedades y aportar información relacionada con familiares directos.

Desafíos de seguridad y privacidad

Uno de los principales riesgos es la posibilidad de reidentificar a una persona mediante el cruce de diferentes fuentes de información. Quitar el nombre o el número de documento no siempre alcanza para garantizar el anonimato, especialmente en el caso de los datos genómicos.

Una secuencia de ADN combinada con otros datos, como la edad o el código postal, puede llegar a permitir la identificación de una persona cuando se la compara con bases de datos públicas o comerciales.

Para reducir estos riesgos y proteger la información se pueden aplicar diferentes medidas:

Privacidad diferencial: Consiste en agregar perturbaciones matemáticas a las consultas estadísticas para dificultar la identificación de una persona concreta dentro de un conjunto de datos.

Cifrado continuo: La información se mantiene cifrada tanto cuando está almacenada como durante su transferencia, utilizando mecanismos de seguridad adecuados.

Cifrado homomórfico: Permite realizar determinados cálculos sobre información cifrada sin tener que descifrarla durante el procesamiento.

Cumplimiento normativo: Es necesario respetar marcos de protección de datos como HIPAA o GDPR. Para esto se utilizan mecanismos como el control de acceso basado en roles (RBAC) y registros de auditoría que permitan dejar constancia de las operaciones realizadas sobre la información.

Fuentes Utilizadas:

<https://www.ukbiobank.ac.uk>

<https://www.genome.gov/about-genomics/fact-sheets/Sequencing-Human-Genome-cost>

<https://doi.org/10.1038/s41586-021-03819-2>

<https://doi.org/10.1056/NEJMoa2034577>

<https://www.hl7.org/fhir>

<https://www.snomed.org>

<https://www.cidrdb.org>

<https://doi.org/10.1126/science.1229566>

<https://www.hhs.gov/hipaa>

<https://gdpr.eu>