Big Data - Analisis Exploratorio de Datos

Utilizando la herramienta Orange Data Mining, importe el archivo de datos hogares.csv y elabore un informe con las respuestas a las preguntas indicadas en esta guía.

Hogares.csv contiene datos ficticios de 100 hogares encuestados.

Condiciones de entrega

- Entrega Grupal: Deben entregarlo por Github con el nombre del grupo -
Plazo máximo: hasta la siguiente clase.

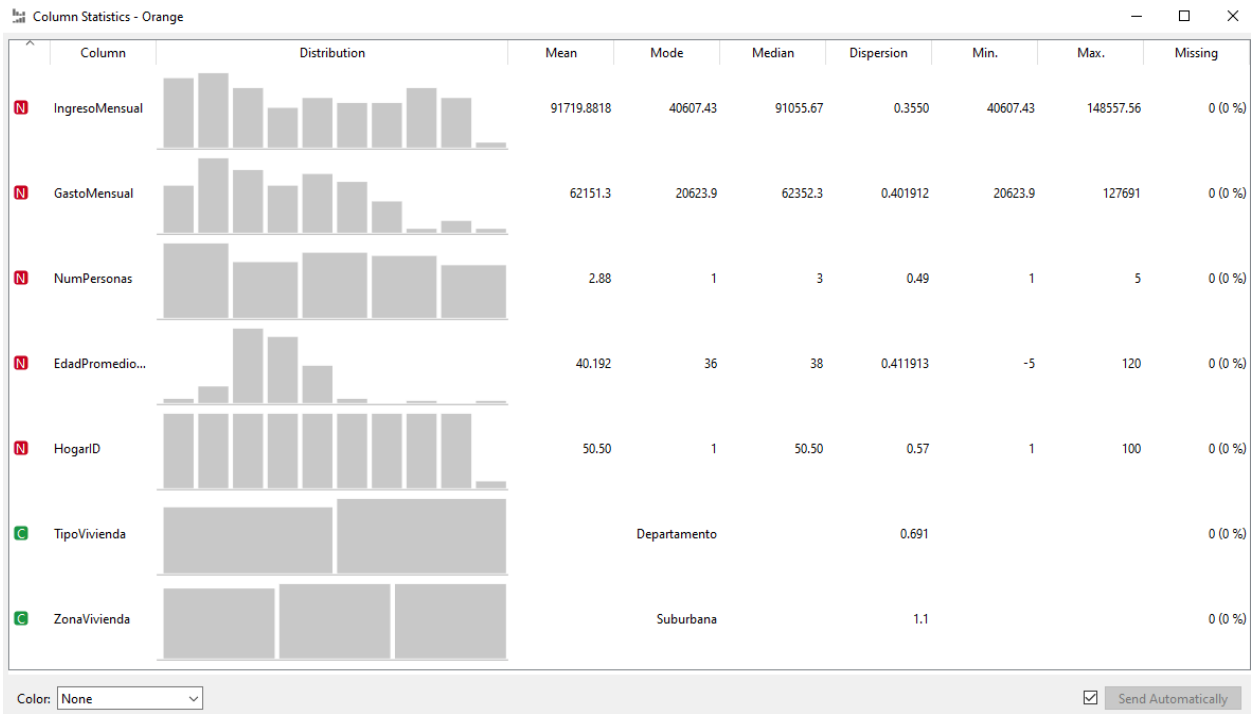
Diccionario de Datos

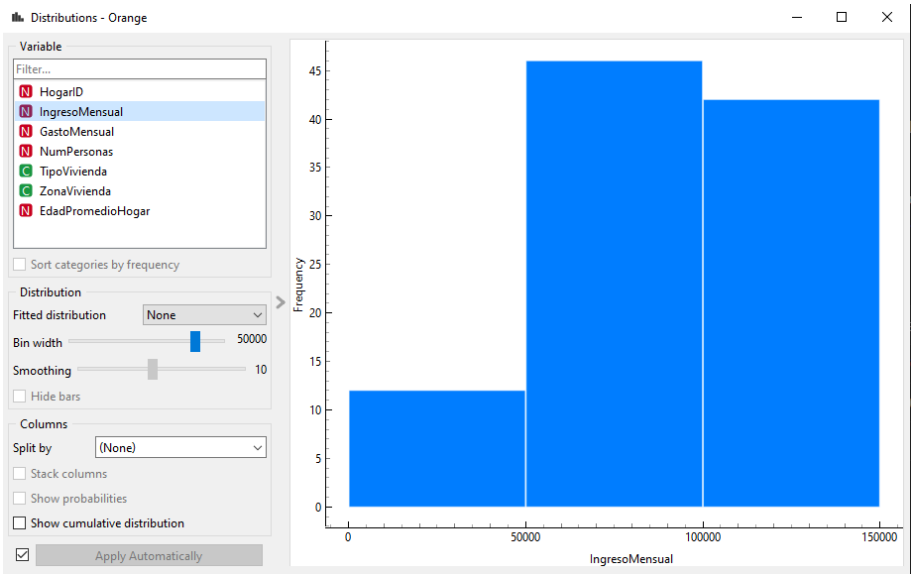
HogarID: Identificador único del hogar, entero que va de 1 a 100.
IngresoMensual: Ingresos totales del hogar por mes, en pesos argentinos (ARS). Representa la suma de todos los ingresos de los miembros del hogar.
GastoMensual: Gastos totales del hogar por mes, en pesos argentinos (ARS). Incluye gastos fijos (como alquiler o hipoteca, servicios, etc.) y gastos variables (como alimentación, transporte, ocio).
NumPersonas: Número de personas que conforman el hogar. Valor entero que indica la cantidad de individuos viviendo en el hogar.
TipoVivienda: Tipo de estructura habitacional donde reside el hogar. Puede ser "Casa" o "Departamento", reflejando las diferentes modalidades de vivienda.
ZonaVivienda: Zona geográfica donde se ubica el hogar. Las categorías incluyen "Urbana", "Suburbana" y "Rural", indicando el contexto geográfico y posiblemente socioeconómico de la vivienda.
EdadPromedioHogar: Edad promedio de los miembros del hogar, en años. Esta variable es un promedio de las edades de todos los individuos que conforman el hogar.

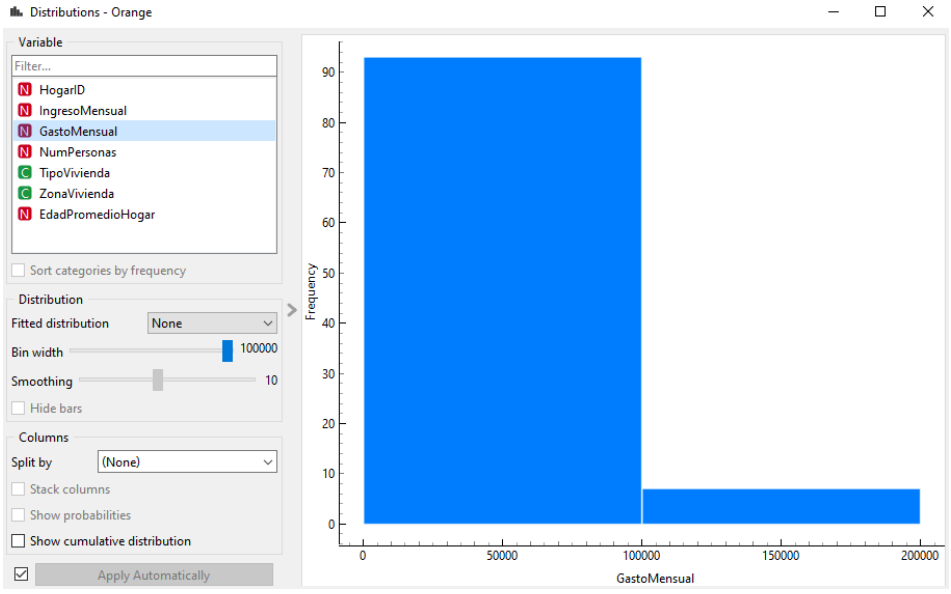
Guía de Preguntas

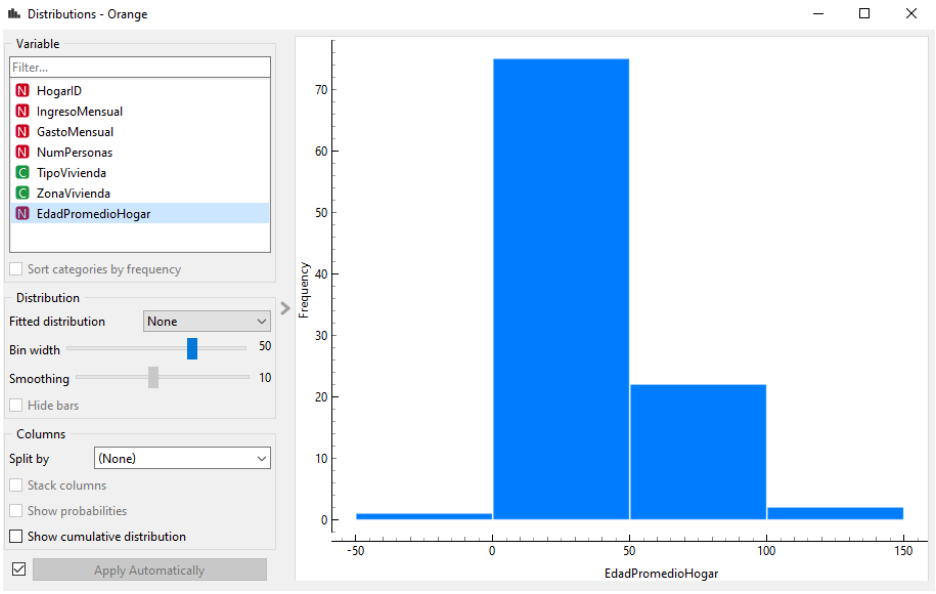
1. Análisis de Tendencia Central y Dispersión (Feature Statistics y Distributions):

Calcule las medidas de tendencia central (media, mediana) y dispersión (varianza, desviación estándar) para las variables IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Los valores encontrados son consistentes con lo que esperarías en un contexto económico real?




Distributions - Orange
Variable
Filter...
HogarID
IngresoMensual
GastoMensual
NumPersonas
TipoVivienda
ZonaVivienda
EdadPromedioHogar
Sort categories by frequency
Distribution
Fitted distribution
None
Bin width
50000
Smoothing
10
Hide bars
Columns
Split by
(None)
Stack columns
Show probabilities
Show cumulative distribution
Apply Automatically
Frequency
IngresoMensual
0
5
10
15
20
25
30
35
40
45
0
50000
100000
150000


Distributions - Orange
Variable
Filter...
HogarID
IngresoMensual
GastoMensual
NumPersonas
TipoVivienda
ZonaVivienda
EdadPromedioHogar
Sort categories by frequency
Distribution
Fitted distribution
None
Bin width
100000
Smoothing
10
Hide bars
Columns
Split by
(None)
Stack columns
Show probabilities
Show cumulative distribution
Apply Automatically
Frequency
GastoMensual
0
10
20
30
40
50
60
70
80
90
0
50000
100000
150000
200000



Variable	Media	Mediana	Desvío	Varianza
Ingreso mensual	91.719,88	91.055,67	32.560	$1{,}06 \times 10^{9}$
Gasto mensual	62.151,29	62.352,30	24.979	$6{,}24 \times 10^{8}$
EdadPromedioHogar	40,19	38,0	16,56	274,1

En ingreso y gasto, la media y la mediana son casi iguales, lo que indica una distribución bastante simétrica. El gasto es en promedio el 68 % del ingreso, lo cual es razonable. Sin embargo, los montos son muy bajos respecto de la realidad argentina actual: según el INDEC, en julio de 2026 una familia tipo necesitó más de $1.500.000 para no ser pobre, y en este dataset el ingreso máximo ronda los $148.000. Por eso concluimos que los datos son ficticios. En la edad, la media (40 años) es razonable, pero la desviación estándar (16,6) está inflada por valores atípicos

2. Verificación de Máximos y Mínimos (Feature Statistics):

Identifique los valores máximos y mínimos para IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Estos valores son realistas? Discuta cualquier valor que parezca inusual o fuera de lo esperado.



EdadPromedioHogar
-5
0.5

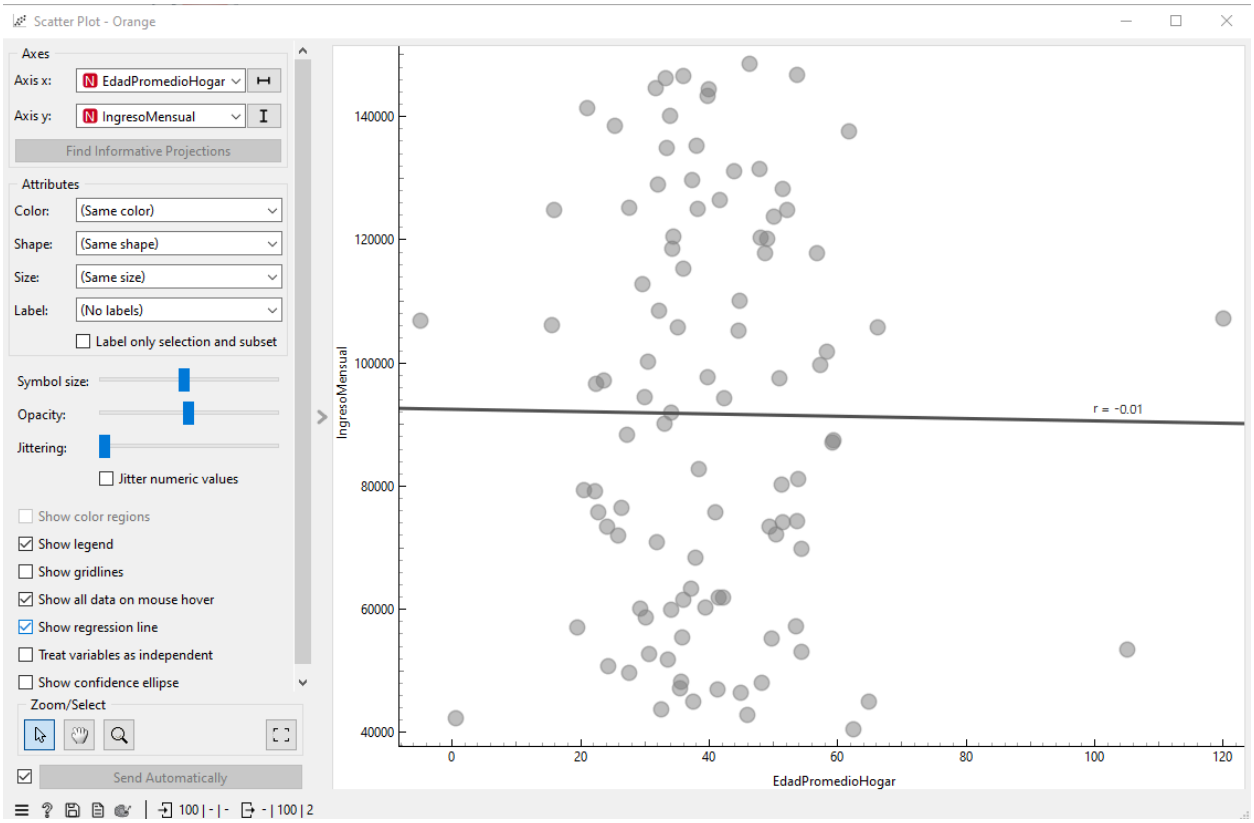
EdadPromedioHogar
120
105

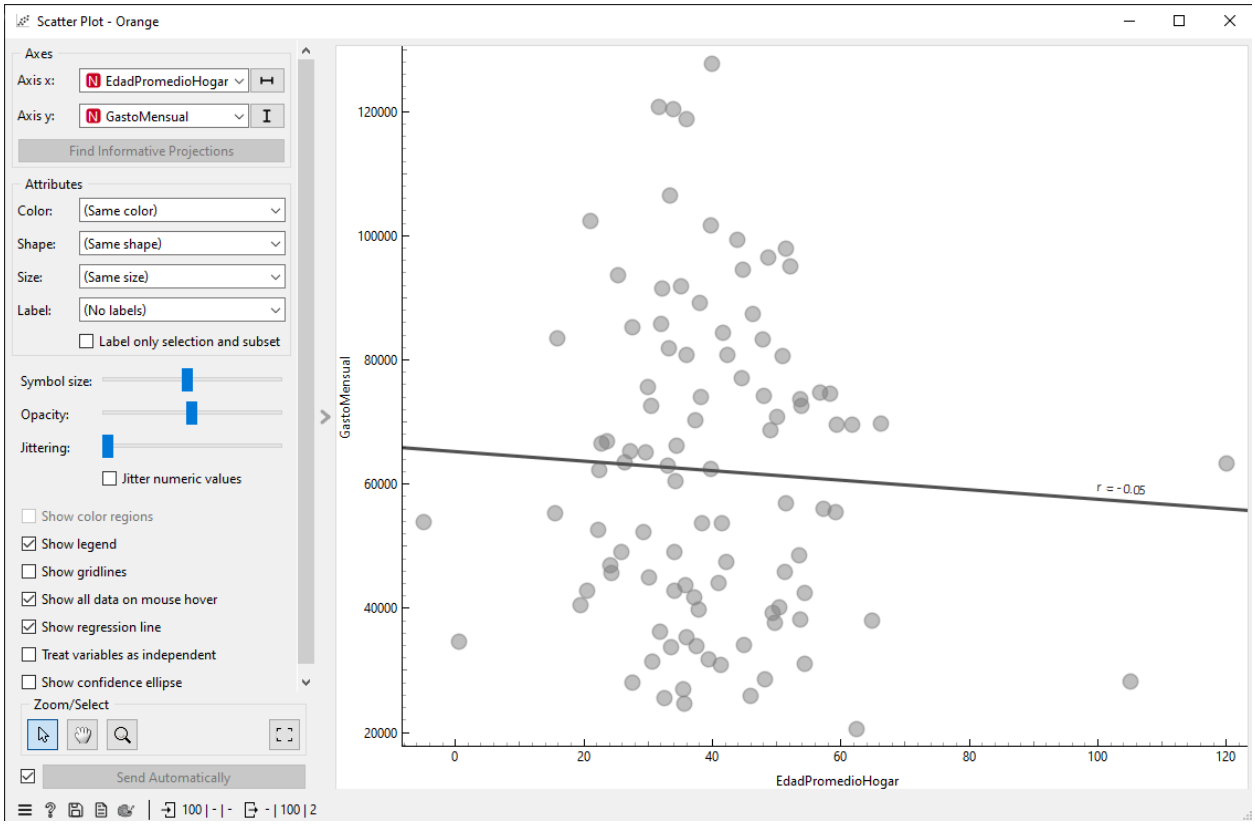
Variable	Mínimo	Máximo
Ingreso mensual	40.607,43 (hogar 73)	148.557,56 (hogar 70)
Gasto mensual	20.623,87 (hogar 73)	127.691,44 (hogar 34)
EdadPromedioHogar	−5 (hogar 31)	120 (hogar 21)

Los valores de ingreso y gasto son coherentes entre sí: ningún hogar gasta más de lo que gana (el gasto va del 50 % al 90 % del ingreso). En cambio, la edad tiene valores no realistas: una edad de −5 es imposible, y 120 años de promedio en un hogar de 5 personas también. Además encontramos 105 años (hogar 41) y 0,5 años (hogar 11), que también son imposibles para un promedio de edad de un hogar. Los consideramos errores de carga.

3. Relación entre Variables (Scatter Plot):

Explore la relación entre el EdadPromedioHogar y otras variables numéricas como IngresoMensual y GastoMensual. ¿Hay alguna tendencia visible que indique cómo la edad promedio del hogar afecta los ingresos y gastos?

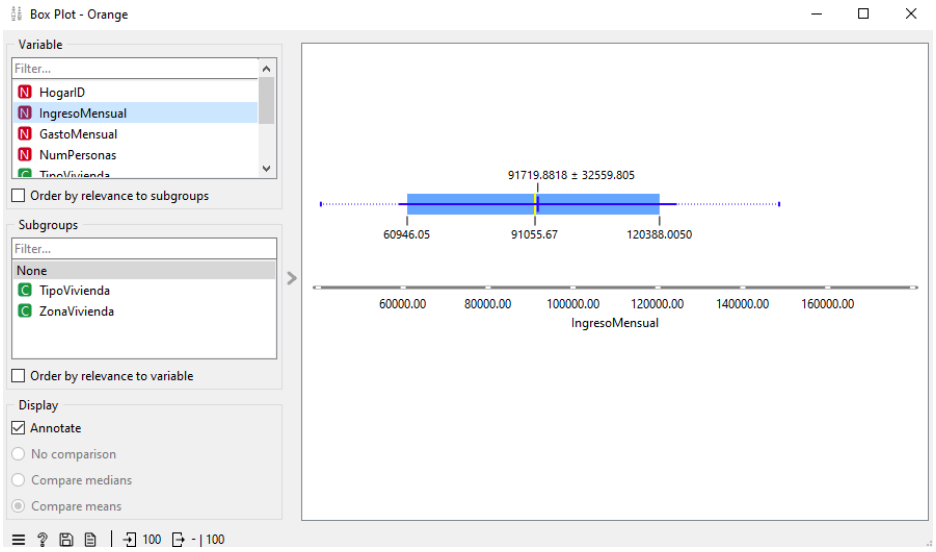


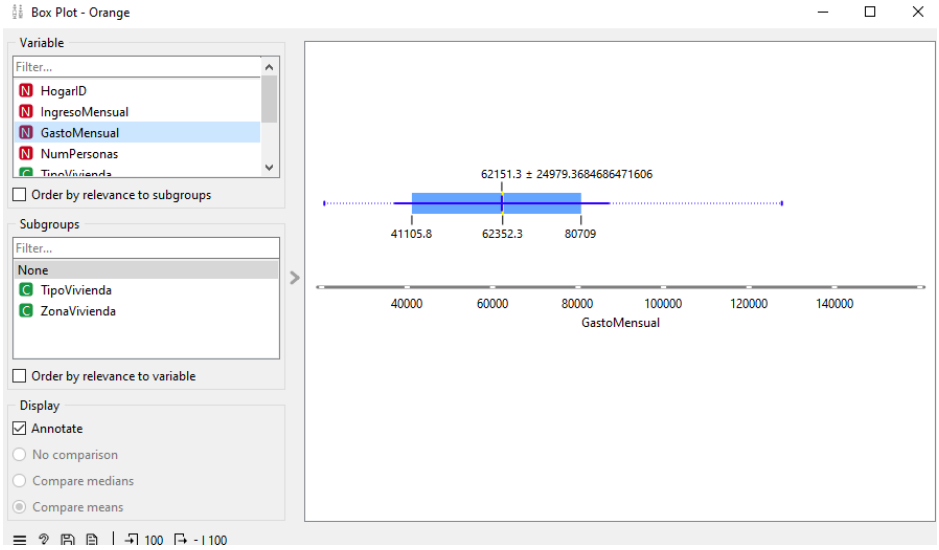


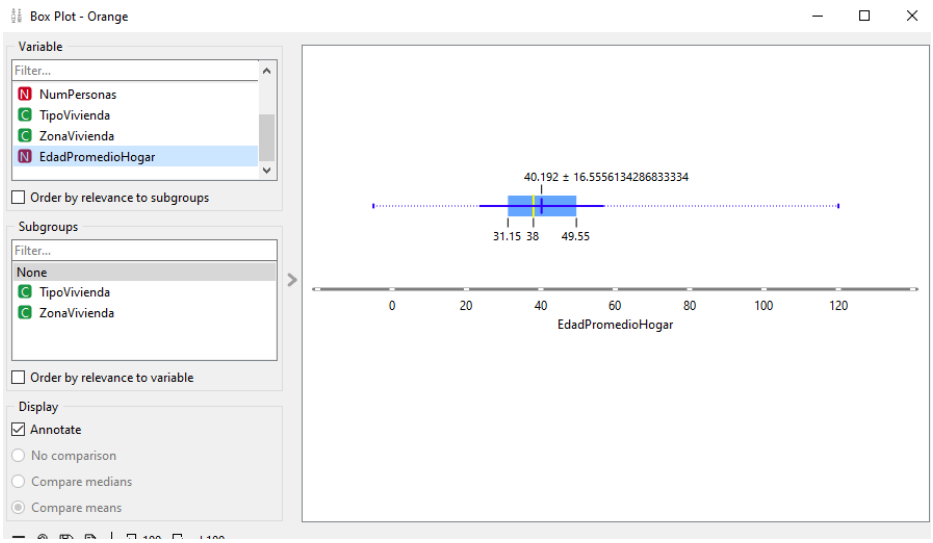
No se observa ninguna tendencia entre la edad promedio del hogar y el ingreso ni el gasto: los puntos forman una nube dispersa y la recta de regresión es casi horizontal. Esto significa que la edad promedio del hogar no influye en cuánto gana o gasta el hogar. Solo se ven algunos puntos aislados en los extremos del eje de la edad, que corresponden a los valores erróneos mencionados antes.

4. Análisis de Outliers (Box Plot):

Utilizando técnicas gráficas, identificar datos atípicos en las variables numéricas. Describa por qué estos puntos podrían considerarse atípicos y qué factores podrían explicar estos valores.


Box Plot - Orange
Variable
Filter...
HogarID
IngresoMensual
GastoMensual
NumPersonas
Order by relevance to subgroups
Subgroups
Filter...
None
TipoVivienda
ZonaVivienda
Order by relevance to variable
Display
Annotate
No comparison
Compare medians
Compare means
100
- | 100
91719.8818 ± 32559.805
60946.05
91055.67
120388.0050
60000.00
80000.00
100000.00
120000.00
140000.00
160000.00
IngresoMensual

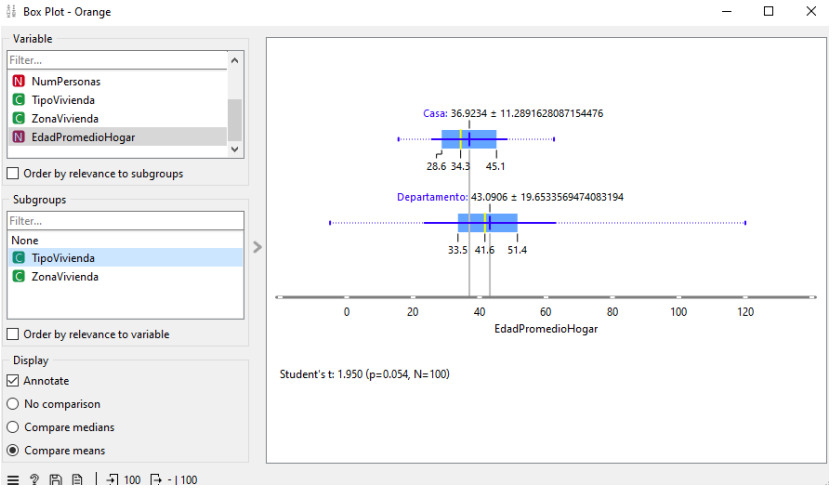

Box Plot - Orange
Variable
Filter...
HogarID
IngresoMensual
GastoMensual
NumPersonas
Order by relevance to subgroups
Subgroups
Filter...
None
TipoVivienda
ZonaVivienda
Order by relevance to variable
Display
Annotate
No comparison
Compare medians
Compare means
100
- | 100
62151.3 ± 24979.3684686471606
41105.8
62352.3
80709
40000
60000
80000
100000
120000
140000
GastoMensual

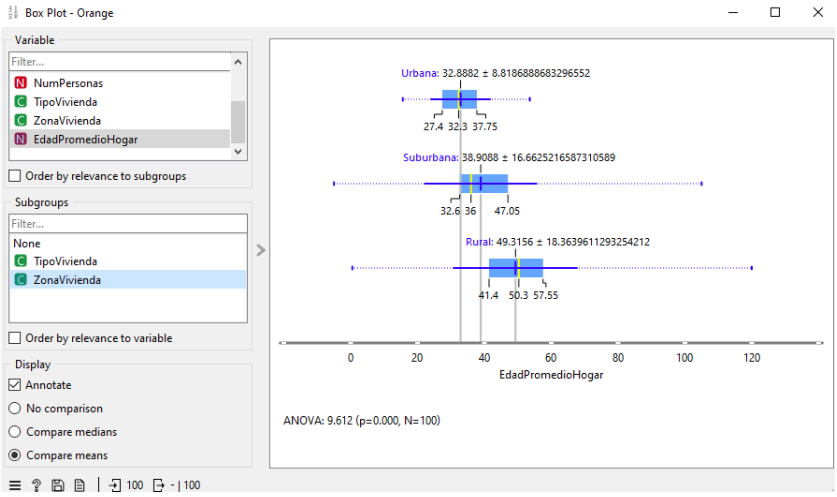


En IngresoMensual y GastoMensual no se detectan datos atípicos: todos los valores quedan dentro de los límites del gráfico de caja. En EdadPromedioHogar hay 4 datos atípicos: 0,5 años (hogar 11), 120 años (hogar 21), −5 años (hogar 31) y 105 años (hogar 41). Son atípicos porque se alejan mucho del resto de los hogares (que van de unos 15 a 66 años) y, además, son valores imposibles o muy poco creíbles para una edad promedio. La explicación más probable son errores de carga o de tipeo en la encuesta.

5. Comparación entre Grupos (Box Plot):

Analice cómo varía la EdadPromedioHogar entre diferentes tipos de vivienda (Casa, Departamento) y zonas de vivienda (Urbana, Suburbana, Rural). ¿Existen diferencias significativas que puedan sugerir patrones demográficos?





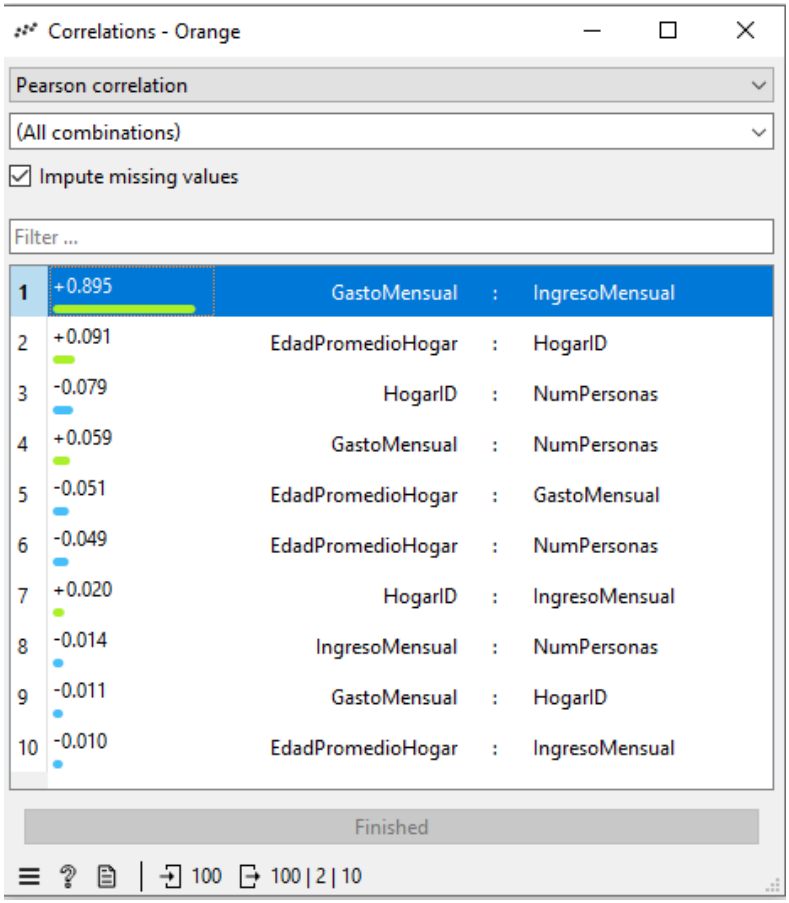
Grupo	Edad Promedio	Mediana
Casa	36,9	34,3
Departamento	43,1	41,6
Rural	49,3	50,3
Suburbana	39,9	36,0

Urbana	32,9	32,3

Por zona hay una diferencia clara: los hogares urbanos son los más jóvenes (mediana de 32 años), los suburbanos están en el medio (36) y los rurales son los de mayor edad (50). Por tipo de vivienda la diferencia es menor: los hogares en departamento tienen una edad algo mayor que los de casa. Cabe aclarar que los 4 valores erróneos de edad están todos en "Departamento" y elevan su promedio y su dispersión. En conjunto, los datos sugieren un patrón demográfico: más jóvenes en zonas urbanas y más mayores en zonas rurales.

6. Correlaciones (Correlations):

Investigue la correlación entre las variables numéricas. ¿Qué relaciones se pueden identificar como relevantes y cómo se interpretan?



La única relación relevante es entre IngresoMensual y GastoMensual (0,895): es fuerte y positiva, es decir que los hogares que ganan más también gastan más, lo cual es esperable. Las demás correlaciones son cercanas a cero, por lo que la edad promedio y la cantidad de personas no se relacionan linealmente con el ingreso ni con el gasto.